

Engenharia de Redes Neurais Artificiais

Aluno: Matheus Paul Lopuch

Exercícios das Aulas

02a_Funcoes_Perda_Redes_Neurais.ipynb

Exercícios

1. Aumente o número de neurônios nos exemplos de classificação e regressão e analise a diferença entre os resultados nos conjuntos de treino e teste. O que ocorreu?
2. Comparar BCELoss e Hinge Loss para o problema linear do Capítulo 01, plotando o resultado. O que é possível verificar de diferença?

Respostas:

1. Classificação:

Ao aumentar o número de neurônios na camada oculta de uma MLP (exemplo: de 4 para 32 ou 64), o modelo tem maior capacidade de aprender padrões complexos.

Se poucos neurônios: resultado similar nos dois conjuntos (boa generalização).

Se muitos neurônios: o modelo pode começar a superajustar (overfitting) os dados de treino, ficando com alta acurácia no treino, mas baixando no teste.

Régressão:

Da mesma forma, ao aumentar neurônios, o erro quadrático médio (RMSE) diminui no treino, mas pode aumentar ou oscilar no teste por overfitting.

O aumento de neurônios aumenta a capacidade de memorização do modelo.

Se exagerado, a rede aprende ruídos do treino, prejudicando a generalização.

2. BCE Loss: Favorece probabilidades próximas de 0 ou 1 para cada classe, sendo mais utilizada em tarefas onde saída é interpretada como probabilidade.

Hinge Loss: Penaliza apenas margens pequenas, típicas do SVM; busca separar as classes com uma margem maior e a saída é +1 ou -1.

Em problemas linearmente separáveis, ambos atingem boa separação, mas Hinge Loss força maior distância entre classes.

Em problemas ruidosos, BCE tende a ser mais robusta para desconto de outliers, enquanto Hinge pode ser sensível a margens próximas.

No gráfico, BCE concentra saídas próximas a 0 ou 1; Hinge aproxima de -1 ou +1.

Comparação BCE Loss vs Hinge Loss

