

Engenharia de Redes Neurais Artificiais

Aluno: Matheus Paul Lopuch

Exercícios das Aulas

05_Paradigmas_Avancados.ipynb

Exercícios

1. Discuta sobre como abordagens como GAN conseguem fazer tarefas de geração de imagens e transformação de dados.
2. Discuta como pré-treino utilizando self-supervised learning é capaz de melhorar resultados de modelos supervisionados.
3. Encontre aplicações recentes de como self-supervised learning vem sendo utilizado em aplicações práticas.

Respostas:

1. Abordagens como as Generative Adversarial Networks (GANs) realizam tarefas de geração de imagens ao treinar dois modelos em competição: um gerador e um discriminador. O gerador aprende a criar dados sintéticos (como imagens) a partir de vetores de ruído aleatório, enquanto o discriminador tenta distinguir entre imagens reais e falsas. O processo adversarial faz com que o gerador produza amostras cada vez mais realistas. Com o tempo, ele consegue gerar imagens tão convincentes que muitas vezes se tornam indistinguíveis das reais. Avanços como StyleGAN permitem controle fino sobre os atributos das imagens geradas (ex.: estilos faciais), e modelos como CycleGAN possibilitam transformar imagens entre domínios diferentes sem a necessidade de pares rotulados (ex.: transformar fotos em pinturas).
2. O self-supervised learning utiliza tarefas auxiliares (tarefas de pretexto) geradas a partir dos próprios dados - por exemplo, prever partes ocultas de imagens (masked autoencoders), prever palavras mascaradas em frases (BERT), ou resolver puzzles de imagens. Ao aprender essas tarefas sem supervisão direta (sem precisar de rótulos externos), o modelo desenvolve representações internas mais ricas e robustas.
3. Visão computacional: Preenchimento de regiões mascaradas em imagens (Masked Autoencoders), colorização automática de fotos em preto e branco, solução de puzzles de imagens e detecção de rotações.

Processamento de linguagem natural: Modelos como BERT, que são pré-treinados para prever palavras ocultas e depois adaptados para múltiplas tarefas (classificação, tradução, pergunta e resposta).

Reconhecimento facial e biometria: Redes siamesas treinadas para aprender similaridades em pares de imagens, verificando assinaturas ou faces sem necessidade de rótulos explícitos.

Aplicações industriais e médicas: Detecção de anomalias em imagens de exames médicos usando autoencoders; análise de áudio e fala aprendendo a reconstruir partes faltantes do sinal; sistemas de recomendação que modelam padrões de comportamento sem feedback explícito do usuário.

Aprendizado contrastivo: Métodos como SimCLR, MoCo e BYOL vêm se destacando para aprendizagem de representações visuais generalizáveis, posteriormente transferidas para tarefas supervisionadas de alto nível com excelentes resultados mesmo usando poucas anotações rotuladas.